

LANGUAGE DETECTION TEKNİKLERİ:

1.1.N-gram

N-gram bir **tekniktir**. Metni kendinden sonra gelen parçalarla gruplama işidir. "Hava çok güzel" cümlesinde;

- **Unigram (1-gram):** "Hava", "çok", "güzel"
- **Bigram (2-gram):** "Hava çok", "çok güzel"

Görevi: Kelimelerin veya harflerin birbirini takip etme sırasını belirler. Dilin yapısını atomlarına ayırır.

1.2. Stop Words

Bunlar dilde çok sık geçen ama tek başına derin bir anlam ifade etmeyen **kelime listeleridir**.

Örneğin; "ve", "veya", "da", "ki", "the", "a", "is" gibi. **Görevi:** Analiz yaparken "gürültüyü" azaltmak için bu kelimeler temizlenirler. Eğer bunlar temizlemezse, istatistik yapıldığında en tepede hep "ve" kelimesini görünür ve asıl konuyu (sağlık, yemek vb.) anlayamayız.

1.3.Olasılıksal Dil modelleri

Temel mantık şudur: Bir dildeki kelimelerin veya karakterlerin bir araya gelme sırası tesadüfi değildir. Her dilin kendine has bir **olasılık dağılımı** vardır. Bilgisayar bir metni gördüğünde şu soruyu sorar: *"Bu karakter diziliminin (n-gram) İngilizce bir veri setinde ortaya çıkma olasılığı nedir?"*

1.3.1.N-Gram ve koşullu olasılık ilişkisi

Olasılıksal modellerde metni küçük parçalara (n-gram) bölmemizin nedeni, matematiksel hesaplamayı basitleştirmektir (**Markov Varsayımı**).

- **Matematiksel Formül:** Bir dizilimin olasılığı, kendinden önceki karakterlere bakılarak hesaplanır:

$$P(c_n | c_{n-1}, c_{n-2}, \dots)$$

- **Örnek:** İngilizcede 'q' harfinden sonra 'u' gelme olasılığı $P(u | q)$ neredeyse %100'dür. Ama 'q'dan sonra 'z' gelme olasılığı neredeyse %0'dır.
- **Dil Tespitinde Kullanımı:** Model, Yelp yorumundaki tüm n-gramların bu "koşullu olasılıklarını" çarpar. Hangi dildeki toplam olasılık daha yüksek çıkarsa (Maximum Likelihood), metin o dile aittir der.

Özetle bunlar bir sürecin aşamalarıdır. **N-gram** verinin nasıl parçalandığını, **Stop-words** hangi parçaların dile daha özgü olduğunu, **Olasılıksal Model** ise bu parçalardan nasıl bir tahmin üretileceğini temsil eder. Yani n-gram ve stop-words **girdi (input)**, olasılıksal model ise **işlemci (processor)** görevindedir.

2.N-GRAM KARAKTER İSTATİSTİĞİ İLE LANGUAGE DETECTION

Geleneksel makine öğrenmesi yaklaşımı (nltk, scikit-learn) ve modern hazır modeller(fastText, langdetect, langid.py) olarak iki farklı yolla yapılabilir.

2. 1. Geleneksel Makine Öğrenmesi Yaklaşımı(NLTK ve Scikit-learn ile Özel Model İnşası)

Bu yöntem, "bilgisayara İngilizceyi bizzat bizim öğretmemiz" yöntemidir. Akademik olarak **denetimli öğrenme (Supervised Learning)** olarak adlandırılır.

2.1.1. Eğitim verisi ve etiketleme

Modeli eğitmek için elimizde iki grup veri olmalıdır. Binlerce İngilizce yorum ve binlerce Türkçe (veya diğer diller) yorum. Bunları bilgisayara "Bu İngilizcedir (en)", "Bu Türkçedir (tr)" diye etiketleyerek veririz.

2.1.2. NLTK kütüphanesi ile metin ön işleme (preprocessing)

Ham Yelp yorumlarını temizleriz. Küçük harfe çevirme, noktalama işaretlerini atma gibi işlemler NLTK ile yapılır. Buradaki amaç, n-gram istatistiği için "temiz" bir veri seti sunmaktır.

2.1.3. Scikit-learn kütüphanesi ile N-gram vektörleştirme (CountVectorizer)

Bu adımda Scikit-learn'ün *CountVectorizer* fonksiyonu devreye girer. Metni karakter n-gramlarına ayırır ve her bir n-gramın kaç kez geçtiğini sayarak bir "sayı tablosuna" (vektör) dönüştürür.

2.1.4. Olasılıksal sınıflandırma (Naïve Bayes)

Bu sayı tablosu **Naïve Bayes** algoritmasına verilir. Algoritma, hangi n-gramların hangi dile ait olma olasılığının yüksek olduğunu hesaplar. Artık modelimiz, yeni bir Yelp yorumu gördüğünde n-gramlarına bakıp "Bu %99 İngilizcedir" diyebilir hale gelir.

2.2.Modern Hazır Modeller

Bu gruptaki kütüphaneler, n-gram istatistiklerini kendi içlerinde barındıran ve "tak-çalıştır" mantığıyla çalışan araçlardır.(Yani kütüphaneyi çağır + tahmin et)

2.2.1.Langdetect Library

Google'ın "language-detection" projesinden Python'a aktarılan Langdetect, karakter n-gramlarını **Naïve Bayes** tabanlı bir olasılıksal model ile analiz eden hazır bir kütüphanedir. Kelime dizilimlerini de hesaplamaya dahil eden bu yapı, pip install langdetect komutuyla kolayca kurulabilmesi sayesinde en sık tercih edilen araçlardan biridir. Yelp gibi büyük veri setlerindeki yorumları tararken yüksek doğruluk sunmasına rağmen, işlem hızı bakımından **FastText** kütüphanesinin gerisinde kalabilmektedir.

2.2.2.Langid.py Library

Dil tespiti için geliştirilen bir diğer önemli araç olan **Langid.py**, tamamen saf karakter n-gram frekansları ve olasılıksal bir sınıflandırıcı üzerine inşa edilmiştir. Bu kütüphanenin en ayırt edici özelliği, herhangi bir harici veri dosyasına veya model indirmeye ihtiyaç duymadan, tüm eğitim bilgisini (n-gram ağırlıklarını) kodun kendi içinde barındırmasıdır. Bu 'hafif' (standalone) yapısı sayesinde, sunucu kurulumlarında veya internet bağlantısının olmadığı ortamlarda bile hızlıca çalışabilir. Yelp yorumları gibi informal ve kısa metinlerde, n-gram dağılımlarını yüksek bir performansla analiz ederek metnin ait olduğu dili belirler.

2.2.3. FastText Library

Facebook AI Research (FAIR) tarafından geliştirilen **FastText**, dil tespiti ve metin sınıflandırma süreçlerinde yüksek hız ve doğruluk sunan modern bir mimari yapıdır. Bu kütüphaneyi geleneksel yöntemlerden ayıran temel fark, karakter n-gramlarını sadece saymakla kalmayıp, bu parçaları *vektör alan modelleri* (word embeddings) ile birleştirerek matematiksel birer ağırlığa dönüştürmesidir. Operasyonel süreçte, 176 farklı dilin "n-gram parmak izleri" ile önceden eğitilmiş lid.176.bin isimli istatistik dosyasını referans alır. Gelişmiş mimarisi sayesinde saniyeler içerisinde on binlerce satırlık veri grubunu analiz etme kapasitesine sahiptir. Bu yüksek işlem performansı, özellikle Yelp yorumları gibi informal dille yazılmış ve yazım hatası içeren büyük ölçekli veri setlerinde, n-gram benzerliği üzerinden güvenilir sonuçlar alınmasını sağlar.

2.2.3.1. FastText ile Yelp Review veri setinde dil tespiti nasıl yapılır?

- **Modelin hazırlanması:** Öncelikle fasttext kütüphanesini projeye dahil ederek, 176 dilin bilgisini içeren o meşhur lid.176.bin dosyasını sisteme yükleriz. Bu dosya, modelin "karar verme tablosu"dur.
- **Metinlerin standartlaştırılması:** Yelp yorumları çok satırlı olabilir. FastText'in doğru çalışması için her yorumu tek bir satıra indirgemek (satır sonu karakterlerini temizlemek) gerekir.
- **Tahmin ve Etiketleme (Prediction)**

Pandas'ın `apply` fonksiyonunu kullanarak, veri setindeki her bir satıra şu soruyu sorarız: "Bu metnin n-gram dizilimi en çok hangi dile benziyor?"

Model bize iki şey döndürür:

1. **Etiket:** Örneğin `__label__en` (İngilizce).
 2. **Olasılık (Score):** Tahminine ne kadar güvendiği (Örn: 0.98).
- **Filtreleme:** Tahmin işlemleri bittikten sonra, veri setinde sadece "en" etiketli olanları tutup, diğer dillerdeki yorumları "gürültü" olarak kabul edip eleriz..